

AI Music Generation — 项目进展报告

对照 Proposal，逐项检查完成情况

总体目标

"端到端 AI 音乐生成系统，从用户情感意图生成个性化 BGM"

✅ 已完成 — generate.py 输入 V-A 坐标 → 输出音频

核心创新 1：连续情感控制

"用连续 V-A 坐标替代离散标签，冻结 backbone 训练轻量 adapter"

要求	状态
V-A 坐标代替 happy/sad	✅ VAEncoder 实现
冻结 backbone 训练 adapter	✅ 多版本训练完成
连续情感调节	✅ 生成时可调 V-A 值
存在不足	❌ 控制效果偏弱（Pearson 最高 0.65），音频有杂音

核心创新 2：Emotion-Fidelity Alignment

"引入'生成情感 → 目标情感'对齐 loss"

✅ 已实现 — emotion_fidelity_loss + EmotionPredictor，v2_fixed 证明了有效性（V Pearson 0.65）

Phase 1：推理基线

"复现 MusicGen 推理"

✅ inference.py — HF + AudioCraft 双后端

Phase 2：数据 & 情感模块

"数据准备、情感标注、情感条件注入模块"

✅ 全部完成

- data_prep.py (MTG/DEAM/CLAP 标注)
- 609 首真实音频下载
- emotion_adapter.py (VAEncoder + Adapter)

Phase 3：微调 & 验证

"微调、超参调优、验证情感可控性"

✅ 完成但效果有限

- 训练了 v1~v5 五个版本
- 最佳 V Pearson = 0.65, A Pearson = 0.58
- 音频质量有下降（FAD 从 1.17 升到 1.71）

Phase 4：评估 & 集成

要求	状态
FAD	✅ 已实现
CLAP Score	✅ 已实现
情感 Fidelity	✅ 已实现
推理 CLI	✅ generate.py
主观听测	❌ 未做
Gradio 界面	❌ 未做
报告	❌ 未整理

训练版本对比

版本	注入方式	V Pearson	A Pearson	说明
v1	加法(768d)	0.27	-0.40	基线
v2	Prefix	-0.11	0.58	Arousal 改善
v2_fixed	Prefix + 修复	0.65	0.07	Valence 最强
v3	平衡版	0.45	0.55	综合最佳
v4	加法(1024d)	—	—	结构验证
v5	Identity 保护	-0.17	0.49	音质略好

一句话总结

核心技术路线全部走通了，量化指标证明情感控制确实有效（V/A Pearson 均大于 0），但控制强度还不够强，音频质量有折损。对于一份课程项目报告来说，已经有了完整的 Data → Train → Evaluate → Generate 流水线和可量化的结果。