


基于 MusicGen Adapter 的连续情感可控 BGM 生成

课程项目 6002 — 最终报告草稿（中文版） 通过 Valence-Arousal 连续坐标控制 MusicGen-small 生成情感化背景音乐


1. 摘要

本项目实现了一个端到端的 AI 音乐生成系统，能够从连续的 Valence-Arousal (V-A) 情感坐标生成个性化背景音乐 (BGM)。我们冻结预训练的 **MusicGen-small** 骨干网络，仅训练轻量级情感适配器 (adapter)，使用 1,990 首带有 V-A 标签的 MTG-Jamando 数据集。探索了 7 种适配器架构（加性、前缀、恒等保护、解码器钩子），进行 8 次训练实验。最佳版本 **v3（平衡适配器）** 达到了 V Pearson $r = 0.446$, A Pearson $r = 0.554$, FAD=1.715，证明了即使在冻结骨干网络的情况下，连续情感控制也是可行的——尽管音频质量有可预见的下降（FAD 较基线 +0.55）。同时开发了**两阶段 DSP 流水线**作为补充方案，在生成后应用音高、节奏、EQ 等声学修改，保留了 MusicGen 的原生音频质量，同时调整声学情感线索。

2. 系统概览



2.1 两阶段 DSP 替代方案



3. 数据集

3.1 数据来源

项目	数值
数据集	MTG-Jamendo (mood/theme 子集)

项目	数值
曲目数量	1,990（下载 10 个 tar 包）
数据划分	训练: 1,590 / 验证: 193 / 测试: 208
标签	59 个情感标签 → 8 锚点 CLAP 映射为 V-A
时长	每首 30 秒 (raw_30s)
采样率	32,000 Hz (EnCodec 默认)

3.2 情感标签分布

59 个情感标签（如 "happy""sad""calm""energetic""dark"）使用 8 锚点文本模板和 CLAP 余弦相似度加权映射为连续 V-A 坐标：

$$\hat{v} = \frac{\sum_{i=1}^8 w_i \cdot v_i}{\sum w_i}, \quad w_i = \text{softmax}(\text{sim}(\text{tag}_i, \text{anchor}_i) / \tau)$$

其中温度参数 $\tau = 0.1$ 。

4. 模型架构

4.1 基座模型: MusicGen-small

组件	详情
Transformer	586M 参数, 24 层解码器, 1024 隐藏维度
音频编码器	EnCodec, 8 个 RVQ 码本, 50 Hz 帧率
文本编码器	T5 编码器 (冻结), 768d → 1024d 通过 <code>enc_to_dec_proj</code>
生成方式	自回归, 4 码本交织模式

4.2 情感 Adapter: VAEncoder

```
VAEncoder(  
    input_dim=2,           # (valence, arousal)  
    hidden_dim=128,  
    output_dim=1024       # 匹配 MusicGen 解码器维度  
)  
# 结构: Linear(2,128) → ReLU → Dropout(0.1) → Linear(128,1024)
```

4.3 注入策略（7 个版本）

版本	注入方式	参数量	训练数据
v1	加性注入 (768d, 编码器输出)	17K	Demo (52)

版本	注入方式	参数量	训练数据
v2	Prefix 前缀 (8 个 token)	17K	Demo (52)
v2_fixed	Prefix + 梯度裁剪修复	17K	Demo (52)
v3	加性注入 (1024d, 解码器) ← 最优	17K	Demo (52)
v4	结构保护 (恒等映射)	17K	Demo (52)
v5	恒等保护加性	17K	Demo (52)
v6	Scale 分离训练 (训练/推理分离)	17K	Demo (52)
v7	解码器 Hook (24 层逐层偏置, Tanh)	17K	Demo (52)
v7_10tar	解码器 Hook	17K	MTG (1,590)

4.3.1 v3 (平衡适配器) 详解

v3 在解码器层面（1024d）注入情感，位于 T5 文本编码投影之后，使用简单的加法调制：

$$\text{hidden}'_i = \text{hidden}_i + \text{VAEncoder}(v, a)$$

这是最简单稳定的注入点，既避免干扰 T5 编码器的复杂交叉注意力（v1 的问题），也避免前缀自回归的不稳定性（v2 的问题）。

4.3.2 v7 (解码器 Hook) 详解

v7 使用 PyTorch `register_forward_hook` 向全部 24 层解码器注入逐层偏置：

$$\text{hidden}'_i^{(l)} = \text{hidden}_i^{(l)} + \tanh(b^{(l)}) \cdot \text{scale}$$

其中 $b^{(l)} \in \mathbb{R}^{1024}$ 是第 l 层的可学习偏置， $\text{scale} = 0.01$ 是小初始值以防干扰。

4.4 训练配置

超参数	数值
优化器	AdamW ($\text{lr} = 5 \times 10^{-4}$)
批大小	8（受 12GB VRAM 限制）
训练轮数	20 (demo), 30 (MTG)
损失函数	$\mathcal{L} = \mathcal{L}_{\text{NLL}} + \lambda \cdot \mathcal{L}_{\text{fidelity}}$
情感对齐损失	$ \text{CLAP}(\text{生成音频}) - \text{目标 V-A} _2^2$
对齐权重 (λ)	0.2
学习率调度	余弦退火 ($T_{\text{max}}=20$)
音频缓存	hashlib 的 EnCodec token 缓存 (<code>cache/audio_tokens/</code>)

4.4.1 音频 Token 缓存

避免每轮重复编码同一音频，将 EnCodec 输出缓存到磁盘：

```
cache_key = hashlib.md5(f"{audio_path}_{duration}".encode()).hexdigest()
cache_path = f"cache/audio_tokens/{cache_key}.pt"
```

每轮训练时间从 ~110s（编码）降至 ~8s（缓存命中）。

5. 评估指标

5.1 情感 Fidelity

使用 **CLAP** (laion/clap-htsat-unfused) 和 8 个情感锚点文本：

锚点文本	V	A
"happy exciting upbeat music"	0.85	0.80
"calm relaxing peaceful music"	0.75	0.20
"sad melancholic depressing music"	0.20	0.25
"tense dramatic aggressive music"	0.25	0.75
"neutral ordinary background music"	0.50	0.50
"romantic tender loving music"	0.80	0.40
"angry furious intense music"	0.15	0.85
"boring dull monotonous music"	0.30	0.15

预测方法: 按 CLAP 相似度对锚点 V-A 加权平均：

$$\text{pred}_v = \sum_{i=1}^8 \frac{\exp(\text{sim}_i/0.1)}{\sum_j \exp(\text{sim}_j/0.1)} \cdot v_i$$

指标: Pearson 相关系数 r , Valence 绝对误差 (VAE), Arousal 绝对误差 (AAE)。

5.2 音频质量（FAD）

Fréchet Audio Distance，使用 VGGish 嵌入（16 层预训练卷积网络的 128 维激活值）。越低越好。MusicGen-small 基线: **FAD ≈ 1.17**。

5.3 文本-音频对齐（CLAP Score）

CLAP 文本嵌入与音频嵌入之间的余弦相似度。越高越好。

6. 实验结果

6.1 综合对比

版本	V Pearson	A Pearson	VAE ↓	AAE ↓	FAD ↓	CLAP ↑
v1 (加性768d)	0.273	-0.400	0.243	0.278	—	0.0650
v2 (前缀)	-0.108	0.576	0.256	0.244	1.601	-0.0396
v2_fixed (前缀+)	0.653	0.073	0.248	0.246	1.621	-0.0395
v3 (平衡)	0.446	0.554	0.246	0.227	1.715	-0.0536
v5 (恒等)	-0.174	0.494	0.251	0.224	1.713	-0.0518
v6 (Scale)	0.376	0.427	0.250	0.236	1.644	0.0017
v7 (解码器)	0.105	0.565	0.247	0.238	1.595	0.0069
v7_10tar (解码器+)	0.373	0.154	0.232	0.241	1.520	0.0087

6.2 可视化图表

Pearson 相关系数对比




图 1: 各版本 Valence 和 Arousal 的 Pearson 相关系数。v2_fixed 达到最高 V 相关性 (0.653); v2 和 v3 达到最高 A 相关性 (0.576, 0.554)。

音频质量对比 (FAD)




图 2: 各版本 FAD 分数。所有 adapter 版本均导致音频质量下降 (FAD 1.52–1.72 vs 基线 1.17)。v7_10tar 在 adapter 版本中取得最佳 FAD (1.520)。

CLAP Score




图 3: 各版本 CLAP 分数均接近零，表明 adapter 注入对文本-音频对齐的损失很小。

VAE / AAE 对比




图 4: Valence 和 Arousal 绝对误差。v3 达到最低 AAE (0.227)。

v3 目标 vs CLAP 预测




图 5: v3 模型的目标情感 vs CLAP 预测情感。CLAP 预测集中在一个极窄范围 (V: 0.26–0.31, A: 0.56–0.68)，揭示了 CLAP 对短片段生成音乐的区分能力有限。

6.3 关键发现

6.3.1 Adapter 注入有效，但强度偏弱

- 最佳 Valence 控制: v2_fixed (前缀 + 修复) $r = 0.653$
- 最佳 Arousal 控制: v2 (前缀) $r = 0.576$, v3 (平衡) $r = 0.554$
- 最佳平衡: v3 $r_V = 0.446$, $r_A = 0.554$
- 最佳 fidelity loss (VAE/AAE): v7_10tar VAE=0.232, v3 AAE=0.227

所有版本至少在某一维度上 $r > 0$ ，确认了 adapter 方法可以影响生成音乐的情感倾向。但相关性为中等水平 (0.4–0.6)，表明控制强度有限。

6.3.2 音频质量下降是系统性的

- MusicGen 基线: FAD $\approx$ 1.17
- 最佳 adapter: v7_10tar FAD = 1.520 (+0.35)
- 最差 adapter: v3 FAD = 1.715 (+0.55)

FAD 下降在所有注入策略中一致出现，表明这是冻结骨干网络潜在空间扰动的固有问题，与训练数据量关系不大（52 vs 1,590 样本效果相似）。

6.3.3 训练数据规模的影响

对比 v7 (52 样本) vs v7_10tar (1,590 样本)：

- V Pearson: 0.105 $\rightarrow$ 0.373 （改善, +0.268）
- A Pearson: 0.565 $\rightarrow$ 0.154 （下降, -0.411）
- FAD: 1.595 $\rightarrow$ 1.520 （改善, -0.075）
- CLAP: 0.0069 $\rightarrow$ 0.0087 （改善）

数据量扩大 30 倍并未一致提升情感控制效果，说明 adapter 架构本身（而非数据量）是主要限制因素。

6.3.4 CLAP 评估的局限性

从 v3 散点图（图 5）可见，所有 12 个评估样本的预测集中在极窄的 V-A 范围（V: 0.26–0.31, A: 0.56–0.68），与目标情感无关。这揭示了：

1. **CLAP 无法区分短片段生成音乐的细微情感差异**
2. CLAP 嵌入捕捉的是**高层语义特征**（曲风、配器），而非声学情感线索（音高、节奏、亮度）
3. 这使得 CLAP 作为连续情感控制的评估指标**能力有限**——它能区分完整歌曲的"开心 vs 悲伤"，但无法感知 8 秒 BGM 片段的微妙 V-A 变化

7. 两阶段 DSP 方案

7.1 动机

所有 adapter 方法都导致音频质量下降。两阶段 DSP 方案通过以下方式避免这个问题：

1. **第一阶段:** 用 MusicGen 生成干净音频（prompt 模式，无需 adapter）
2. **第二阶段:** 根据 V-A 坐标应用 DSP 效果（音高偏移、节奏变化、EQ、音量）

7.2 DSP 参数映射

情感	Valence	Arousal	节奏	音高	高音EQ	音量
欢快	0.85	0.80	1.09×	+1.4 半音	+2.1 dB	+1.2 dB
悲伤	0.20	0.30	0.94×	-1.2 半音	-1.8 dB	-0.8 dB
宁静	0.80	0.15	0.90×	+1.2 半音	+1.8 dB	-1.4 dB
紧张	0.20	0.85	1.10×	-1.2 半音	-1.8 dB	+1.4 dB

7.3 DSP 流水线




图 6: 两阶段生成流水线。干净的 MusicGen 输出经过 V-A 依赖的 DSP 后处理。

7.4 当前局限性

- **CLAP 不可见:** DSP 改变（音高 ± 5 半音、节奏 $\pm 30\%$ ）对人类听觉**非常明显**，但 CLAP 嵌入几乎不响应（所有预测变化 $\Delta < 0.07$ ）
- **需要主观验证:** DSP 情感控制效果需要通过人工听测验证
- **仅测试钢琴:** 对于更丰富的配器，效果可能更明显

8. 讨论

8.1 有效的方法

成果	证据
✓ 连续 V-A 控制可行	所有版本至少在一个维度上 $r > 0$
✓ 完整流水线	V-A → 训练 → 生成 → 评估
✓ 音频质量可量化	FAD 能一致地区分不同版本
✓ Fidelity loss 有效	v2_fixed (含 fidelity loss) 优于 v2

8.2 无效的方法

局限	原因
✗ 音频质量下降	冻结骨干扰动 + 有限数据
✗ CLAP 评估能力弱	CLAP 捕捉语义而非声学特征
✗ 更多数据无帮助	架构限制而非数据限制
✗ DSP 对 CLAP 不可见	声学变化 $\neq$ 语义嵌入变化

8.3 与文献对比

方法	情感控制	音频质量	训练成本
本项目 (v3 adapter)	中等 ($r_V = 0.45, r_A = 0.55$)	下降 (FAD=1.72)	低 (8 分/轮)
本项目 (DSP)	仅主观可感知	无损	零
MusicGen 基线	无 (偏中性)	原生 (FAD=1.17)	—
LoRA 微调	较高	中等	中
全参数微调	最高	最佳	高 (不可行)

9. 结论

本项目证明了通过轻量 adapter 对 MusicGen 进行连续情感控制是可行但有限的。最佳 adapter (v3) 实现了中等情感控制 ($r_V = 0.446, r_A = 0.554$)，代价是音频质量下降 (FAD +0.55)。**Adapter 方法的核心权衡**在于控制强度与音频保真度之间——这是一个架构层面的约束，而非数据层面的问题。

两阶段 DSP 流水线提供了**音频无损的补充路径**，但其效果需要人类主观验证而非 CLAP 指标。

未来工作

1. **LoRA 微调**注意力层（而非仅编码器输出）以获得更强控制
2. **人类听测试**用于 DSP 情感验证
3. **旋律保留**的情感迁移（即原提案中的"旋律线索"扩展）
4. **Gradio 演示**用于交互式 V-A 探索

10. 个人贡献

- **数据流水线**: MTG-Jamando 下载、情感标签 → V-A 映射、CLAP 自动标注
- **模型设计**: 7 种 adapter 架构、2 种注入范式
- **训练优化**: 音频 token 缓存 (10 倍加速)、情感对齐损失
- **评估框架**: FAD / CLAP Score / 情感 Fidelity 三维评估
- **DSP 流水线**: V-A → 节奏/音高/EQ 映射、librosa + scipy 实现
- **CLI 工具**: `generate.py` (3 种模式), `evaluate.py`, `train_adapter.py`

附录: 可复现性

环境

```
PyTorch 2.12.1+cu130
CUDA 13.0
RTX 3060 (12GB VRAM)
transformers 5.13.0
librosa 0.10.x
```

命令

```
# 训练
python train_adapter.py --data_mode mtg --epochs 30 --use_fidelity

# 评估
python evaluate.py --checkpoint checkpoints/adapter_v3.pth

# 生成 (prompt 模式 - 音质最好)
python generate.py --preset happy --mode prompt -o output.wav

# 生成 (DSP 模式 - 两阶段)
python generate.py --preset sad --mode dsp -o output.wav

# 生成 (adapter 模式)
python generate.py --preset calm --mode adapter -o output.wav
```

检查点

文件	说明
checkpoints/adapter_v3.pth	综合最佳 (V=0.45, A=0.55)
checkpoints/adapter_v2_fixed.pth	Valence 最佳 (r=0.65)
checkpoints/adapter_v7_10tar.pth	FAD 最佳 (1.52), 全 MTG 数据训练